

Simulateur d'entraînement au contrôle aérien augmenté par IA : validation systématique et étude comparative multi-modèles de la chaîne vocale STT $\rightarrow$ LLM $\rightarrow$ TTS

Nicolas Marano

Université de Reims Champagne-Ardenne, Centre de calcul ROMEO (NVIDIA GH200)

maranoniko@gmail.com

Juillet 2026

Résumé

Nous présentons un simulateur d'entraînement au contrôle aérien dont la boucle radio est entièrement pilotée par la voix : l'élève contrôleur parle sur un canal VHF simulé, la parole est transcrite (Whisper adapté au domaine par LoRA), interprétée en ordres structurés par un grand modèle de langage contraint par une base de connaissances OACI, validée par des gardes déterministes (bornes physiques, graphe secteur), exécutée dans le simulateur de trafic BlueSky, puis collationnée par une voix de synthèse dégradée canal radio. Toutes les briques d'inférence respectent le contrat d'API OpenAI-compatible : le même système fonctionne indifféremment sur supercalculateur (ROMEO, GH200), sur GPU grand public local (RTX 4070) ou sur API cloud, par simple changement de configuration.

Nous validons chaque étage par des mesures contrôlées et reproductibles : (i) géométrie de conflit : 1 000 000 géométries Monte-Carlo sur 5 graines, 0 désaccord de décision avec une vérité numérique indépendante, et confrontation à BlueSky sur 200 rencontres ($F_1 = 1,0$) ; (ii) reconnaissance vocale : WER sur corpus VHF réels (ATCO2, UWB-ATCC), l'adaptation LoRA réduisant le WER ATCO2 de 71,9 % à 28,5 % ; (iii) interprétation : comparaison appariée (McNemar exact, correction de Holm, rapports de cotes) de cinq LLM locaux quantifiés et d'un parseur à règles sur 116 clairances annotées, dont des strates hors grammaire et adversariales ; le meilleur modèle local (Mistral-7B) atteint 81,9 % d'exactitude TrafScript exacte, contre 100,0 % pour le parseur à règles sur la phraséologie standard mais 70,8 % hors grammaire ; (iv) synthèse : coût temps réel et intelligibilité aller-retour ; (v) boucle complète : 76 % de clairances parlées correctement exécutées (témoin texte : 88 %), latence vocale totale moyenne de 2,6 s. Deux campagnes de généralisation complètent l'étude : la même batterie rejouée à *protocole identique* contre la façade supercalculateur (GH200, modèles pleine précision, tunnel SSH de production), isolant l'effet de la quantification 4 bits et établissant la parité STT entre points de déploiement ; et une validation avec locuteur humain réel (80 % de réussite au micro brut contre 76 % en voix synthétique), dont l'analyse des échecs fonde une taxonomie actionnable. La campagne historique de validation se ré-exécute à l'identique (mêmes métriques champ à champ). L'ensemble du banc de mesure, des corpus annotés et des scripts d'analyse est versionné avec le projet.

1 Introduction

La formation initiale des contrôleurs aériens repose sur des simulateurs dont le coût d'exploitation est dominé par un facteur humain : chaque session requiert des *pseudo-pilotes*, opérateurs qui prononcent les collationnements et exécutent les instructions dans le simulateur. Automatiser ce rôle (comprendre une clairance parlée, l'exécuter fidèlement, la collationner d'une voix réaliste) est un cas d'usage exigeant pour les modèles de fondation : la phraséologie OACI est un langage contraint, le canal VHF (300–3 400 Hz) dégrade fortement le signal, et toute erreur d'interprétation exécutée dans le simulateur fausse l'exercice pédagogique.

Ce travail décrit un système complet et son évaluation : une application web d'entraînement (radar, strips, poste instructeur, exercices notés) adossée au simulateur de trafic open source BlueSky [1], dont la boucle radio est assurée par trois services d'inférence interchangeables au contrat OpenAI-compatible. Nos contributions :

1. une **architecture de sûreté en couches** : aucune sortie de LLM n’atteint le simulateur sans passer par une validation déterministe (bornes physiques, actions autorisées, waypoints du secteur), et toute panne de fournisseur est remontée visiblement (jamais de repli silencieux) ;
2. un **banc de mesure de bout en bout**, versionné et seedé, couvrant les cinq étages (géométrie/simulateur, STT, LLM, TTS, boucle vocale complète) avec intervalles de confiance bootstrap, IC de Wilson et tests appariés de McNemar ;
3. une **étude comparative multi-modèles reproductible sur GPU grand public** : cinq LLM open-weights quantifiés (1 à 7 milliards de paramètres) évalués *à travers le code de production*, comparés à un parseur à règles de référence, sur un corpus annoté stratifié (phraséologie standard, paraphrases hors grammaire, bruit STT, français, cas mixtes valide+invalide, négatifs de sécurité) ;
4. la **quantification de l’adaptation au domaine** : gain du LoRA ATC sur Whisper-small mesuré sur enregistrements VHF réels, effet du filtre passe-bande d’inférence, et coût (RTF) des points de déploiement local, cluster et cloud ;
5. une **comparaison cluster/local à protocole strictement identique** (mêmes corpus, mêmes graines, même chaîne cliente) entre la façade GH200 (modèles pleine précision) et un GPU portable grand public (modèles quantifiés), ainsi qu’une **validation avec locuteur humain réel** de la boucle vocale complète.

Questions de recherche. L’évaluation est organisée autour de cinq questions falsifiables :

- RQ1** Le prédicteur de conflit embarqué est-il *exact* au sens d’une vérité numérique indépendante, et la garantie « conflit par construction » des exercices tient-elle statistiquement ?
- RQ2** Quel gain de reconnaissance vocale l’adaptation LoRA apporte-t-elle sur des enregistrements VHF réels, et le filtre passe-bande d’inférence du système est-il justifié ?
- RQ3** Un LLM local remplace-t-il avantageusement un parseur à règles pour l’extraction d’ordres — globalement, et hors de la grammaire du parseur ? Les différences entre modèles survivent-elles à une correction de comparaisons multiples ?
- RQ4** Les gardes déterministes suffisent-elles à empêcher toute exécution d’ordre dangereux, même avec des modèles faibles ?
- RQ5** La boucle vocale complète est-elle exploitable en conditions réalistes (canal radio dégradé, locuteur humain, fournisseur distant), à quelle latence, et où échoue-t-elle ?

2 Système

2.1 Architecture

La figure 1 présente l’architecture. Le navigateur (React, canvas radar 60 fps, push-to-talk) communique avec un serveur FastAPI par REST et WebSocket (~ 8 Hz). Le simulateur BlueSky, non thread-safe, vit dans un thread unique alimenté par une file de commandes. Les trois briques d’inférence sont des services REST au contrat OpenAI standard (`/v1/audio/transcriptions`, `/v1/chat/completions`, `/v1/audio/speech`), configurés par variables d’environnement : changer de fournisseur, qu’il s’agisse de la façade auto-hébergée sur ROMEO, de la façade locale llama.cpp / faster-whisper / Kokoro (fournie avec le banc de mesure) ou d’une API cloud, ne modifie ni le code ni le comportement de validation.

2.2 Sûreté en couches

Le contrat d’interprétation impose un tableau JSON d’ordres `{callsign, action ∈ {HDG, ALT, SPD, ADDWPT}, value}`. En aval du modèle, une bibliothèque pure et testée (`03_bluesky_connector`) applique : coercition stricte de type (rejet des booléens, NaN, infinis), bornes physiques (HDG $[0; 360]^\circ$, ALT $[0; 45\,000]$ ft, SPD $[0; 350]$ kt), et validation des waypoints contre le graphe secteur. L’application ajoute deux gardes : un indicatif absent du radar produit un silence radio (réalisme assumé), et une incohérence sémantique montée/descente (« climb » vers un niveau inférieur au niveau courant) est rejetée avec message. Enfin, aucune panne de fournisseur n’est rattrapée silencieusement : erreur typée $\rightarrow$ HTTP 502 $\rightarrow$ événement visible dans le journal de bord de l’interface.




FIGURE 1 – Architecture. Les briques IA (orange) sont des services OpenAI-compatibles interchangeables ; aucune sortie LLM n’atteint le simulateur sans la couche de validation déterministe (vert).

2.3 Adaptation au domaine

La brique STT est `openai/whisper-small` affiné par LoRA ($r = 32$, $\alpha = 64$, cibles q/v -proj) sur les corpus radiotéléphoniques réels UWB-ATCC et ATCOSIM [5, 6], avec un front-end reproduisant le canal : passe-bande Butterworth d’ordre 6, 300–3 400 Hz, et bruit additif (SNR 5–20 dB) à l’entraînement. Le prompt LLM inline une base de connaissances OACI originale de 9 fiches ($\sim 2,5$ Ko), couvrant les actions, les contextes informatifs à ignorer (QNH, transferts de fréquence) et la règle « en cas de doute, ne rien produire », ainsi que des indices NER (indicatif détecté). Le collationnement TTS applique la phraséologie OACI (chiffres parlés, alphabet radio, indicatifs en téléphonie) avec une voix stable par aéronef (hachage CRC32 de l’indicatif dans un pool configurable) et la dégradation VHF appliquée *côté client*, donc identique quel que soit le fournisseur.

3 Méthodologie

Principe. Chaque étage est mesuré *à travers le code de production* (mêmes prompts, mêmes clients HTTP, même post-traitement), jamais par une reconstitution. Tous les protocoles sont seedés et versionnés (`bench/`) ; chaque script écrit un JSON auto-porteur (protocole + résultats) et les figures et tableaux de cet article en sont générés automatiquement.

Statistiques. Moyennes : IC à 95 % par bootstrap percentile ($B = 10^4$, graine fixée) [13]. Proportions : IC de Wilson [12]. Comparaisons de systèmes sur corpus apparié : test exact de McNemar [10] (binomial, bilatéral) pour les issues binaires, avec correction de Holm-Bonferroni [11] sur la famille complète des paires et rapport de cotes n_{01}/n_{10} comme taille d’effet ; bootstrap apparié pour les différences de WER. Percentiles de latence par interpolation linéaire. Aucune valeur de l’article n’est saisie à la main : tableaux et macros numériques sont générés depuis les JSON de mesure (`docs/article/gen_tables.py`), et l’environnement logiciel exact est capturé au moment des campagnes (tableau 1).

Corpus d’interprétation. 116 clairances annotées en TrafScript attendu *après* validation : 68 cas historiques dans la grammaire du parseur de référence (10 catégories dont 10 négatifs) et 48 cas étendus couvrant paraphrases hors grammaire, bruit type STT (hésitations, répétitions), français parlé, nombres composés, immatriculations épelées, multi-ordres à connecteurs, cas *mixtes* (ordre valide + ordre invalide dans la même phrase, l’invalide devant être filtré et le valide conservé) et 14 négatifs de sécurité supplémentaires (hors bornes, hors schéma, instructions relatives, information pure). Un cas est réussi si le multi-ensemble TrafScript produit est exactement celui attendu.

Corpus audio. STT : 150 extraits par corpus, tirés au sort (graine 42, durées 0,4–30 s) de deux corpus VHF *réels*, ATCO2-1h (871 extraits disponibles, domaine cible jamais vu à l’entraînement du LoRA) et UWB-ATCC test (2822 extraits, domaine d’entraînement) ; les IC bootstrap par extrait reflètent cette taille d’échantillon. Normalisation texte et WER identiques au protocole historique du projet (comparabilité avec les chiffres publiés). Boucle E2E : énoncés contrôleur synthétisés (voix Windows SAPI, jamais utilisée ailleurs dans le banc), passés dans le canal radio simulé (bruit SNR 12 dB puis passe-bande VHF).

TABLE 1 – Environnement logiciel exact des campagnes (reproductibilité).

Composant	Version
Python (bench)	3.12.10
OS	Windows 11
torch	2.6.0+cu124
transformers	5.12.1
peft	0.19.1
datasets	5.0.0
faster_whisper	1.2.1
ctranslate2	4.8.0
llama_cpp	0.3.32
kokoro_onnx	?
onnxruntime	1.27.0
jiwer	?
numpy	2.5.0
scipy	1.18.0
soundfile	0.14.0
fastapi	0.139.0
requests	2.34.2
GPU (local)	NVIDIA GeForce RTX 4070 Laptop GPU
CUDA (torch)	12.4
Pilote NVIDIA	591.74
Python (app)	3.12.10
bluesky-simulator	1.1.1
numpy (app)	2.4.6
Modeles GGUF (Q4_K_M)	Llama-3.2-1B-Instruct-Q4_K_M (0.81 Go), Mistral-7B-Instruct-v0.3-Q4_K_M (4.37 Go), Qwen2.5-1.5B-Instruct-Q4_K_M (0.81 Go)

Matériel et points de déploiement. Étude locale : portable Windows 11, RTX 4070 Laptop 8 Go, i9-13900H, 32 Go (versions logicielles exactes au tableau 1). LLM locaux : llama.cpp (CUDA), GGUF Q4_K_M, température 0, graine 42 — Llama-3.2-1B-Instruct, Qwen2.5-1.5B-Instruct, Qwen2.5-3B-Instruct (deux conversions GGUF indépendantes pour contre-vérification) et Mistral-7B-Instruct-v0.3. Campagne cluster (août 2026) : la façade de production sur nœud GH200 (Whisper-small+LoRA, Mistral-7B-Instruct-v0.3 *bf16*, XTTS voix clonées), atteinte par le tunnel SSH de production, soumise aux mêmes protocoles seedés — Mistral-7B étant évalué des deux côtés, la paire bf16/Q4_K_M isole l’effet de quantification à modèle constant. Les mesures historiques de `validation/results_perf.json` (2026-07) restent citées comme référence de première campagne.

4 Résultats

4.1 Géométrie de conflit et simulateur

Prédiction CPA vs vérité numérique. Sur 1 000 000 géométries aléatoires (5 graines $\times$ 200 000 ; positions ± 80 NM, caps uniformes, vitesses sol 150–550 kt), la décision du prédicteur de conflit embarqué (extrapolation linéaire, horizon 120 s, seuil 5 NM) coïncide avec une recherche numérique indépendante sur grille fine ($\Delta t = 0,05$ s, horizon 300 s) dans *tous* les cas : 0 désaccord sur 10^6 décisions. L’écart maximal sur la distance au point de rapprochement est de 0,05 NM, borné par la quantification d’affichage du champ (arrondi au dixième de NM) ; la campagne historique, qui comparait les valeurs non arrondies, mesurait un écart maximal de $5,52 \times 10^{-4}$ NM (figure 2).

Confrontation à BlueSky. La campagne historique (200 rencontres stabilisées, 55 % biaisées conflit, seuils 5 NM/120 s) donne précision, rappel et F_1 de 1,0 (113 conflits), MAE de 0,067 NM sur d_{CPA} et 0,71 s sur t_{CPA} . Nous l’avons ré-exécutée intégralement : toutes les métriques sont identiques champ à champ à celles versionnées (seules les durées d’exécution diffèrent), ce qui établit la reproductibilité du protocole.

Garantie de conflit des exercices. Le générateur d’exercices construit des paires d’aéronefs convergeant vers un point commun avec temps d’arrivée égaux. Sur 2 000 tirages, la garantie est vérifiée à 100,0 % : d_{CPA} analytique maximal de 0,082 NM (moyenne 0,018 NM, très inférieure à la norme de séparation de 5 NM) et écart maximal entre l’instant de croisement annoncé et le CPA calculé de 0,7 s (figure 3).




FIGURE 2 – Erreur de d_{CPA} du prédicteur embarqué vs grille numérique fine, par graine (200 000 géométries chacune). L’erreur est bornée par l’arrondi d’affichage (0,05 NM) ; la décision de prédiction est exacte (0 désaccord / 10^6).




FIGURE 3 – Garantie « conflit par construction » du générateur d’exercices : distribution du d_{CPA} analytique sur 2 000 tirages seedés.

Montée en charge. BlueSky headless avance 10 s de simulation avec un facteur temps réel moyen de $\times 105$ à 5 aéronefs et encore $\times 67$ à 200 aéronefs (5 répétitions par point, figure 4) : la simulation n’est jamais le facteur limitant de la boucle vocale.

4.2 Reconnaissance vocale (STT)

Le tableau 2 et la figure 5 comparent cinq systèmes sur les deux corpus VHF réels, avec et sans passe-bande VHF d’inférence (protocole de production : *avec*). Trois enseignements :

1. **L’adaptation LoRA est le facteur dominant.** Sur ATCO2 (domaine jamais vu à l’entraînement), le LoRA réduit le WER de 71,9 % (vanilla) à 28,5 %, gain relatif d’environ 60 % confirmé par bootstrap apparié (différence significative, l’IC de la différence excluant zéro). Sur UWB-ATCC (domaine d’entraînement), le WER tombe à 19,2 %.
2. **Le passe-bande d’inférence est cohérent avec l’entraînement.** Il améliore ou laisse inchangé le modèle adapté (entraîné dans ce domaine), tandis que son effet sur les modèles génériques est faible : le choix de production (`bandpass=True`) est validé.
3. **Le déploiement local est réaliste.** En greedy sur RTX 4070, tous les systèmes tournent bien en deçà du temps réel (figure 6) ; faster-whisper offre le meilleur débit brut, la voie transformers+LoRA offrant elle la meilleure exactitude.

4.3 Interprétation des clairances (LLM)

Le tableau 3 et les figures 7–9 présentent l’étude comparative sur les 116 clairances. Lecture :




FIGURE 4 – Montée en charge BlueSky headless (5 répétitions par point, IC bootstrap à 95 %).

TABLE 2 – STT : WER corpus (%) et RTF par système, corpus VHF réels, sans/avec passe-bande VHF d’inférence. Normalisation du protocole historique du projet ; décodage greedy.

	atco2 (n=150)			uwb_atcc (n=150)		
	brut	VHF	RTF	brut	VHF	RTF
hf-small	71,1	71,9	0,018	101,2	91,9	0,023
hf-small-lora	29,7	28,5	0,017	19,3	19,2	0,020
fw-tiny	100,9	106,0	0,106	120,1	123,3	0,112
fw-base	88,1	90,1	0,091	107,4	110,8	0,148
fw-small	70,6	71,5	0,092	93,2	92,3	0,130
romeo-lora	–	28,2	0,553	–	19,2	0,578

1. **Le parseur à règles est parfait dans sa grammaire, nul en dehors.** 100,0 % sur la phraséologie standard, 70,8 % sur les strates hors grammaire : c’est précisément l’écart que le LLM doit combler.
2. **L’échelle compte, mais pas de façon monotone.** L’exactitude globale croît de 3,4 % (Llama-3.2-1b) à 81,9 % (Mistral-7B) ; les différences entre modèles sont testées par McNemar apparié (tableau 4). Une anomalie notable : Qwen2.5-3B s’effondre ($\approx 24\%$) là où son cadet 1.5B excelle : il honore le message système (vérifié) mais viole le schéma (champ `callsign` omis, clés JSON non citées). Nous avons exclu un artefact de conversion en ré-évaluant un second GGUF indépendant (bartowski) : résultat identique (23,3 %). Autre artefact *réellement* rencontré puis corrigé : le gabarit de conversation Mistral-v0.3 de llama.cpp *perd le message système* (vérifié par test dédié), faisant chuter Mistral-7B à 21 % ; la fusion système→utilisateur du gabarit officiel restaure 81,9 %. Ces deux cas illustrent pourquoi l’évaluation doit se faire *à travers la pile de déploiement réelle*.
3. **La sécurité tient d’abord aux gardes déterministes.** Les taux de rejet des négatifs par système (tableau 3) montrent que même les petits modèles, qui hallucinent des ordres, sont largement rattrapés par la validation de bornes et de waypoints, illustration chiffrée de l’architecture en couches (§2.2).
4. **Latence exploitable en local.** Le meilleur compromis qualité/latence locale est Mistral-7B (81,9 %, 0,8s par clairance en moyenne) ; Mistral-7B, identique au modèle ROMEO, sert de point de comparaison cluster/local.

Génération de situations. Sur les 20 descriptions instructeur de la validation historique (116 contraintes vérifiables : effectifs, niveaux, caps, azimuts, espacements, types), le générateur à règles atteint 100,0 % et le meilleur LLM local 71,8 % (figure 10) : la tâche, plus ouverte (géométrie du secteur, espacement en traînée), reste sensiblement plus difficile que l’extraction d’ordres pour les petits modèles.

4.4 Synthèse vocale (TTS)

Le tableau 5 et la figure 11 évaluent Kokoro-82M (4 voix), Windows SAPI et les voix de pilotes clonées XTTS de la façade cluster sur les collationnements produits par le générateur de phraséologie du projet. Kokoro synthétise à RTF 0,336 et son intelligibilité aller-retour (WER d’un juge STT fixe) reste à 21,4 %




FIGURE 5 – WER par système sur corpus VHF réels (IC bootstrap 95 % du WER moyen par extrait ; losanges : WER corpus). Protocole de normalisation identique aux mesures historiques du projet.




FIGURE 6 – Facteur temps réel STT (log) : tous les systèmes sont largement sous le temps réel sur GPU grand public.

après dégradation VHF : la coloration radio coûte peu d’intelligibilité, conformément à l’objectif (réalisme sans perte pédagogique). Les voix clonées XTTS (timbre « pilote » volontairement réaliste, débit rapide) synthétisent à $RTF \approx 0,78$ mais leur WER aller-retour est plusieurs fois supérieur (tableau 5) : le réalisme du timbre se paie en intelligibilité mesurée — compromis immersion/clarté assumé et *réglable*, le choix du fournisseur TTS étant une ligne de configuration. La métrique étant relative (biais du juge partagé), seuls les écarts entre moteurs sont interprétables.

4.5 Boucle vocale complète (E2E)

La figure 12 et le tableau 6 mesurent la boucle complète de production sur 25 clairances parlées (canal radio SNR 12 dB) ; le tableau 7 compare ensuite cette condition de référence aux conditions cluster (§4.6) et locuteur humain (§4.7) sur les mêmes énoncés. En local : 76 % d’exécutions exactes en condition voix, contre 88 % en condition témoin texte (mêmes clairances, sans STT) ; l’écart chiffre le coût résiduel de l’étage STT, et l’attribution des échecs (transcription déviée vs interprétation) est donnée dans le tableau 6. La latence vocale totale (STT + LLM + TTS, dégradation VHF cliente comprise) est de 2,6s en moyenne (p95 3,2s), compatible avec le rythme d’un exercice d’entraînement, l’étage LLM dominant le budget.

4.6 Comparaison cluster/local à protocole identique (ROMEO)

À la réouverture du supercalculateur (août 2026), la façade GH200 (Whisper-LoRA, Mistral-7B *bf16 non quantifié*, XTTS voix clonées) a été soumise, à travers le tunnel SSH de production, aux *mêmes* protocoles

TABLE 3 – Interprétation : exactitude TrafScript exacte (IC Wilson 95 %), par strate, rejet des négatifs de sécurité, JSON strict, latence et débit (116 clairances ; chaîne de production complète).

Système	Globale	IC 95 %	Std.	Hors gr.	Nég. rejetés	JSON	Lat. moy.
Parseur à règles	87,9	[81 ; 93]	100	71	96	100	0,00 s
Llama-3.2-1b	3,4	[1 ; 9]	1	6	17	22	2,81 s
Mistral-7B	81,9	[74 ; 88]	85	77	75	100	0,82 s
Qwen2.5-3b-bartowski	23,3	[17 ; 32]	21	27	96	69	0,42 s
Qwen2.5-1.5b	75,0	[66 ; 82]	79	69	75	97	0,32 s
Qwen2.5-3b	24,1	[17 ; 33]	19	31	100	46	0,34 s
Mistral-7B ROMEO (bf16)	83,6	[76 ; 89]	84	83	75	98	1,95 s

TABLE 4 – Tests exacts de McNemar entre systèmes appariés sur les 116 clairances (n_{01} : A correct / B faux ; RC = rapport de cotes n_{01}/n_{10} ; p_{Holm} : correction de Holm-Bonferroni sur la famille complète de 21 comparaisons ; * : $p_{Holm} < 0,05$).

Paire (A vs B)	n_{01}	n_{10}	RC	p	p_{Holm}
Parseur à règles vs Llama-3.2-1b	98	0	∞	$< 10^{-4}$	$< 10^{-4*}$
Parseur à règles vs Mistral-7B	19	12	1,6	0,2810	1,0000
Parseur à règles vs Qwen2.5-3b-bartowski	76	1	76,0	$< 10^{-4}$	$< 10^{-4*}$
Parseur à règles vs Qwen2.5-1.5b	25	10	2,5	0,0167	0,1167
Parseur à règles vs Qwen2.5-3b	75	1	75,0	$< 10^{-4}$	$< 10^{-4*}$
Parseur à règles vs Mistral-7B ROMEO (bf16)	18	13	1,4	0,4731	1,0000
Llama-3.2-1b vs Mistral-7B	0	91	0,0	$< 10^{-4}$	$< 10^{-4*}$
Llama-3.2-1b vs Qwen2.5-3b-bartowski	0	23	0,0	$< 10^{-4}$	$< 10^{-4*}$
Llama-3.2-1b vs Qwen2.5-1.5b	1	84	0,0	$< 10^{-4}$	$< 10^{-4*}$
Llama-3.2-1b vs Qwen2.5-3b	0	24	0,0	$< 10^{-4}$	$< 10^{-4*}$
Llama-3.2-1b vs Mistral-7B ROMEO (bf16)	0	93	0,0	$< 10^{-4}$	$< 10^{-4*}$
Mistral-7B vs Qwen2.5-3b-bartowski	73	5	14,6	$< 10^{-4}$	$< 10^{-4*}$
Mistral-7B vs Qwen2.5-1.5b	16	8	2,0	0,1516	0,7579
Mistral-7B vs Qwen2.5-3b	73	6	12,2	$< 10^{-4}$	$< 10^{-4*}$
Mistral-7B vs Mistral-7B ROMEO (bf16)	6	8	0,8	0,7905	1,0000
Qwen2.5-3b-bartowski vs Qwen2.5-1.5b	7	67	0,1	$< 10^{-4}$	$< 10^{-4*}$
Qwen2.5-3b-bartowski vs Qwen2.5-3b	3	4	0,8	1,0000	1,0000
Qwen2.5-3b-bartowski vs Mistral-7B ROMEO (bf16)	6	76	0,1	$< 10^{-4}$	$< 10^{-4*}$
Qwen2.5-1.5b vs Qwen2.5-3b	65	6	10,8	$< 10^{-4}$	$< 10^{-4*}$
Qwen2.5-1.5b vs Mistral-7B ROMEO (bf16)	10	20	0,5	0,0987	0,5924
Qwen2.5-3b vs Mistral-7B ROMEO (bf16)	6	75	0,1	$< 10^{-4}$	$< 10^{-4*}$

seedés que la pile locale : mêmes 116 clairances, mêmes échantillons ATCO2/UWB, mêmes 25 énoncés E2E, même chaîne cliente. Les lignes « ROMEO » des tableaux 2, 3, 5 et 7 en donnent les résultats ; trois lectures :

1. **Effet de la quantification isolé (RQ3).** Mistral-7B bf16 (ROMEO) atteint 83,6 % contre 81,9 % pour le même modèle en Q4_K_M local ; le test de McNemar apparié sur la paire ($n_{01} = 6$, $n_{10} = 8$, $p_{Holm} = 1,00$, tableau 4) ne détecte *pas* d'écart significatif à cette taille d'échantillon : sur cette tâche, la quantification 4 bits est au plus un effet de l'ordre du point de pourcentage — le facteur de confusion « précision numérique » de la campagne locale est ainsi levé, dans les limites de puissance discutées en §6.
2. **Parité STT.** Le même adaptateur LoRA servi par la façade GH200 produit, sur les mêmes extraits, des WER cohérents avec l'exécution locale (tableau 2, ligne `romeo-lora`) : le point de déploiement ne change pas la qualité de transcription, seulement la latence (tunnel compris).
3. **Boucle complète.** En bout en bout, la pile ROMEO exécute 76 % des clairances parlées (témoin texte 88 %) pour une latence vocale moyenne de 9,0 s, à comparer à 76 % / 2,6 s pour la pile locale (tableau 7). Les latences ROMEO incluent l'aller-retour du tunnel SSH : c'est la réalité opérationnelle du poste de travail.

Fait opérationnel documenté : pendant la campagne locale (juillet 2026), le cluster était *entièrement indisponible* (maintenance de sécurité, correctifs RedHat) ; l'application est restée fonctionnelle par simple bascule du `.env` vers la façade locale, puis a rebasculé vers la façade GH200 pour la présente campagne — validation en conditions réelles, dans les deux sens, de l'argument de continuité de service du contrat OpenAI-compatible.




FIGURE 7 – Exactitude TrafScript exacte par système (IC Wilson 95 %), globale et par strate. La chaîne évaluée est celle de production (prompt + KB OACI + validation déterministe).

TABLE 5 – TTS : RTF et intelligibilité aller-retour (juge faster-whisper small (cuda, greedy)) sur 30 collationnements OACI.

Moteur / voix	RTF	WER propre	WER après VHF
kokoro/af_bella	0,348	22,5 %	25,4 %
kokoro/am_adam	0,346	18,2 %	17,7 %
kokoro/bf_emma	0,339	21,2 %	19,8 %
kokoro/bm_george	0,310	26,0 %	22,6 %
sapi/Microsoft Zira Desktop	0,003	16,0 %	18,2 %
xtts-romeo/pilot_1	0,930	68,8 %	64,9 %
xtts-romeo/pilot_2	0,780	75,1 %	92,0 %
xtts-romeo/pilot_3	0,777	79,0 %	72,1 %

4.7 Validation avec locuteur humain

Les énoncés synthétiques (SAPI) contrôlent parfaitement le protocole mais ne représentent ni l’accent ni la prosodie d’un utilisateur réel. Un locuteur humain (francophone, non contrôleur) a donc enregistré les 25 clairances du protocole E2E via le micro de l’application, rejouées dans la chaîne exacte du banc en deux conditions : *micro brut* (ce que l’application entend au push-to-talk) et *canal radio simulé* (bruit SNR 12 dB + passe-bande, graine commune avec les autres conditions). Résultats au tableau 7 : 80 % de réussite au micro brut (IC [61 ; 91]) et 72 % après canal radio, contre 76 % pour la voix synthétique — la boucle tient face à une voix réelle non native, au prix d’échecs supplémentaires attribués à l’étage STT. L’analyse qualitative des échecs (§5) est plus instructive que les taux : accent sur certains indicatifs (« ryanair »), confusion phonétique *two/to* transformant « two five zero » en « to five zero » (soit SPD 50, *dans les bornes* donc non filtré), et un défaut indépendant du locuteur — l’indicatif épilé « csa one delta zulu » parfois réassemblé fautivement par le LLM (CSAD12Z au lieu de CSA1DZ) malgré une transcription parfaite, défaut également observé en condition synthétique.

5 Discussion

Choix du point de déploiement. Les trois points de déploiement mesurés dessinent une matrice simple. *Cluster (GH200, bf16)* : meilleure qualité d’interprétation (83,6 %) et voix clonées, mais dépendance à une infrastructure mutualisée dont l’indisponibilité de juillet 2026 a rappelé le coût, et latences tributaires du tunnel. *Local (RTX 4070, Q4_K_M)* : qualité proche (81,9 % pour le même Mistral-7B), latence vocale moyenne de 2,6 s, aucune dépendance réseau, coût matériel unique de l’ordre d’un poste de travail — le point




FIGURE 8 – Exactitude par catégorie de clairance et par système.

TABLE 6 – Boucle vocale complète : configuration, réussite, attribution des échecs et latences par étage.

Clairances parlées (canal SNR 12 dB)	25
Réussite voix (IC Wilson)	76 % [57 ; 89]
Réussite témoin texte	88 %
Échecs attribués STT / LLM / fournisseur	3 / 3 / 0
Latence STT (moy. / p95)	0,36 / 0,42 s
Latence LLM (moy. / p95)	1,06 / 1,42 s
Latence TTS (moy. / p95)	1,15 / 1,36 s
Latence totale (moy. / p95)	2,57 / 3,20 s

recommandé pour un produit d’entraînement autonome. *Cloud* : couvert par le contrat mais volontairement non évalué (biais commercial, variabilité temporelle) ; le banc est prêt à l’y soumettre. Dans tous les cas, les gardes déterministes restent identiques : la qualité du modèle ne conditionne que le taux d’ordres *corrects*, jamais la sûreté des ordres *exécutés* (RQ4 : zéro ordre hors bornes exécuté sur l’ensemble des campagnes, tous modèles confondus).

Taxonomie des échecs résiduels. Les échecs observés en boucle complète se rangent en quatre classes. (i) *Acoustiques* : accents et indicatifs peu fréquents (« ryanair » humain) — traitables par élargissement du corpus d’adaptation LoRA. (ii) *Phonétiquement ambigus mais dans les bornes* : « two five zero » entendu « to five zero » produit SPD 50, valide pour le validateur (bornes 0–350 kt) mais opérationnellement invraisemblable en croisière — un plancher de plausibilité par phase de vol (borne basse dynamique) fermerait cette classe sans toucher au contrat. (iii) *Réassemblage d’indicatifs épelés par le LLM* : CSA12Z au lieu de CSA1DZ malgré une transcription parfaite, observé avec voix humaine et synthétique — défaut du modèle, pas du locuteur ; une normalisation déterministe des indicatifs épelés *en amont* du LLM (le module `atc_callsign` existe déjà côté post-traitement) le neutraliserait. (iv) *Style de sortie du modèle* : l’anomalie Qwen2.5-3B (schéma violé) et la perte du message système par un gabarit de conversation (Mistral/llama.cpp), détectées uniquement parce que l’évaluation traverse la pile réelle — argument méthodologique central de ce travail.




FIGURE 9 – Latence d’interprétation et débit de génération des modèles locaux (RTX 4070, llama.cpp Q4_K_M, température 0).




FIGURE 10 – Conformité aux contraintes du générateur de situations (IC Wilson 95 %).

Portée pour la formation. Le facteur temps réel du simulateur ($\times 67$ à 200 aéronaves), la latence vocale (2,6s locale) et le collationnement dégradé canal radio placent le système dans l’enveloppe d’un poste d’entraînement individuel réaliste ; le barème d’exercice, adossé à des conflits garantis par construction (100,0 %), fournit une note reproductible et contestable — c’est-à-dire auditable, chaque événement étant tracé dans le rapport JSON de débrief.

6 Menaces à la validité

Interne. Les énoncés E2E synthétiques contrôlent le protocole mais sous-estiment la variabilité de la parole spontanée ; la condition locuteur humain (§4.7) borne ce risque, mais avec $n = 1$ locuteur et $n = 25$ énoncés — les IC de Wilson, larges, en rendent compte, et le recrutement de locuteurs supplémentaires est la première extension prévue. L’intelligibilité TTS partage le biais du juge STT entre moteurs (métrique relative). L’erreur CPA mesurée est bornée par l’arrondi d’affichage du champ comparé. Les latences ROMEO incluent le tunnel SSH (réalité du poste, mais non séparée de l’inférence). **Externe.** La comparaison bf16/Q4_K_M isole désormais l’effet de quantification (§4.6) ; les fournisseurs cloud restent non évalués (le contrat les rend interchangeables, pas équivalents). Le secteur simulé est unique (CTR Reims, 7 fixes) ; la généralisation à d’autres espaces exige de régénérer graphe et exercices. **Construction.** Le corpus d’interprétation (116 cas) et sa vérité terrain ont été rédigés par un unique annotateur ; deux garde-fous l’encadrent — la moitié « phraséologie standard » est vérifiée mécaniquement par le parseur à règles (100 % d’accord), et l’intégralité du corpus annoté est publiée avec le code pour contre-expertise. La vérité terrain des cas mixtes suppose la politique « filtrer l’invalidé, garder le valide », qui est celle du système ; un système plus




FIGURE 11 – TTS : coût de synthèse et intelligibilité objective aller-retour, avant/après canal VHF.

TABLE 7 – Boucle vocale complète : conditions comparées (25 clairances identiques, graine de bruit commune ; IC de Wilson 95 % ; attribution des échecs par WER sémantique ; latences client, tunnel compris pour ROMEO).

Condition	Réussite	IC 95 %	Échecs STT/LLM	Lat. moy./p95
SAPI → pile locale	19/25 (76 %)	[57 ; 89]	3/3	2,6/3,2 s
SAPI → pile ROMEO (tunnel)	19/25 (76 %)	[57 ; 89]	3/3	9,0/13,6 s
Locuteur humain (nicolas), micro brut → pile locale	20/25 (80 %)	[61 ; 91]	4/1	2,3/2,7 s
Locuteur humain (nicolas), canal radio simulé → pile locale	18/25 (72 %)	[52 ; 86]	6/1	2,7/3,6 s

conservateur serait pénalisé par cette métrique — le taux de rejet des négatifs est donné séparément pour cette raison. **Puissance.** Avec 116 cas appariés et des effectifs discordants faibles (typiquement 10–30 paires), le test de McNemar ne détecte que des écarts de plusieurs points de pourcentage : les paires non significatives du tableau 4 (parseur vs Mistral, bf16 vs Q4_K_M) se lisent « écart au plus modeste », et non « équivalence démontrée » — une démonstration d’équivalence exigerait un protocole dédié (TOST) sur corpus élargi.

7 Travaux liés

Les corpus ATCOSIM, UWB-ATCC et le challenge ATCO2 [6, 5, 4] ont établi la reconnaissance vocale ATC comme domaine propre, avec des WER de systèmes génériques dégradés de plusieurs dizaines de points par le canal VHF ; le retour d’expérience à grande échelle d’ATCO2 [9] confirme le rôle décisif de l’adaptation au domaine, aujourd’hui dominée par l’affinage paramétriquement efficace (LoRA [3]) de modèles de fondation comme Whisper [2]. BlueSky [1] est le simulateur ouvert de référence pour la recherche ATM. L’utilisation de LLM contraints pour l’interprétation de clairances rejoint les travaux sur l’extraction structurée fiable ; notre apport est triple : l’évaluation *système* (à travers la chaîne de production complète, gardes comprises, jusqu’aux gabarits de conversation des moteurs d’inférence) plutôt que l’évaluation isolée du modèle ; la comparaison appariée à un parseur à règles sur corpus stratifié avec contrôle des comparaisons multiples ; et la triangulation entre points de déploiement (bf16 cluster / Q4 local) et types de locuteurs (synthétique / humain) à protocole constant. Les moteurs d’inférence locaux utilisés sont llama.cpp, CTranslate2/faster-whisper et Kokoro-82M (ONNX), cités ici comme logiciels¹.

8 Conclusion

Nous avons présenté un simulateur d’entraînement ATC dont chaque étage (géométrie de conflit, reconnaissance vocale, interprétation, synthèse, boucle complète) est validé par des mesures contrôlées, seedées et versionnées avec le code, et dont les réponses aux cinq questions de recherche sont chiffrées. RQ1 : base géométrique exacte (10^6 décisions sans désaccord, $F_1 = 1,0$ face à BlueSky, conflits d’exercice garantis à 100,0 %). RQ2 : gain STT majeur et significatif de l’adaptation au domaine sur VHF réel (71,9 % → 28,5 % sur ATCO2), passe-bande d’inférence validé. RQ3 : hiérarchie nette des LLM locaux, Mistral-7B Q4 statistiquement indiscernable du parseur à règles globalement et supérieur hors grammaire ; la paire bf16/Q4 à

1. github.com/ggml-org/llama.cpp, github.com/SYSTRAN/faster-whisper, huggingface.co/hexgrad/Kokoro-82M.




FIGURE 12 – Boucle vocale complète : taux de réussite (voix vs témoin texte, IC Wilson) et décomposition de la latence.

modèle constant (83,6 % vs 81,9 %) borne le coût de la quantification. RQ4 : zéro ordre hors bornes exécuté sur l’ensemble des campagnes, quel que soit le modèle. RQ5 : boucle vocale à 76 % de réussite (2,6s de latence moyenne) en local, 76 % via la façade cluster, et 80 % avec locuteur humain réel — avec une taxonomie d’échecs actionnable. L’architecture au contrat OpenAI-compatible rend ces points de déploiement interchangeables sans toucher au code ni aux gardes de sûreté, qui restent déterministes et testées ; la bascule cluster↔local a été exercée dans les deux sens en conditions réelles.

Reproductibilité. Code, corpus annotés, scripts de benchmark, résultats JSON (locaux *et* ROMEO : `bench/results/*_romeo.json`, locuteur humain : `human_e2e.json`), environnement logiciel capturé (tableau 1) et génération automatique des figures et tableaux de cet article : répertoires `bench/`, `validation/` et `docs/article/` du dépôt. La campagne historique ré-exécutée produit des métriques identiques champ à champ.

Références

- [1] J. M. Hoekstra et J. Ellerbroek, « BlueSky ATC Simulator Project : an Open Data and Open Source Approach », *ICRAT*, 2016.
- [2] A. Radford *et al.*, « Robust Speech Recognition via Large-Scale Weak Supervision », *ICML*, 2023.
- [3] E. Hu *et al.*, « LoRA : Low-Rank Adaptation of Large Language Models », *ICLR*, 2022.
- [4] J. Zuluaga-Gomez *et al.*, « ATCO2 corpus : A Large-Scale Dataset for Research on Automatic Speech Recognition and Natural Language Understanding of Air Traffic Control Communications », 2022.
- [5] L. Šmídl *et al.*, « Air Traffic Control Communication (UWB-ATCC) Corpus », Université de Bohême de l’Ouest, 2019.
- [6] K. Hofbauer, S. Petrik et H. Hering, « The ATCOSIM Corpus of Non-Prompted Clean Air Traffic Control Speech », *LREC*, 2008.
- [7] A. Q. Jiang *et al.*, « Mistral 7B », 2023.
- [8] Équipe Qwen, « Qwen2.5 Technical Report », 2024.
- [9] J. Zuluaga-Gomez *et al.*, « Lessons Learned in Transcribing 5000 h of Air Traffic Control Communications for Robust Automatic Speech Understanding », *Aerospace*, 10(10) :898, 2023.
- [10] Q. McNemar, « Note on the sampling error of the difference between correlated proportions or percentages », *Psychometrika*, 12(2) :153–157, 1947.
- [11] S. Holm, « A simple sequentially rejective multiple test procedure », *Scandinavian Journal of Statistics*, 6(2) :65–70, 1979.
- [12] E. B. Wilson, « Probable inference, the law of succession, and statistical inference », *Journal of the American Statistical Association*, 22(158) :209–212, 1927.
- [13] B. Efron, « Bootstrap methods : another look at the jackknife », *The Annals of Statistics*, 7(1) :1–26, 1979.
- [14] OACI, *Doc 4444 : Gestion du trafic aérien (PANS-ATM)*, 16^e éd. (phraséologie de référence ; la base de connaissances du projet est un contenu original, sans extrait verbatim).