

Simulateur d'entraînement au contrôle aérien augmenté par IA : validation systématique et étude comparative multi-modèles de la chaîne vocale STT $\rightarrow$ LLM $\rightarrow$ TTS

Nicolas Marano

Université de Reims Champagne-Ardenne, Centre de calcul ROMEO (NVIDIA GH200)

maranoniko@gmail.com

Juillet 2026

Résumé

Nous présentons un simulateur d'entraînement au contrôle aérien dont la boucle radio est entièrement pilotée par la voix : l'élève contrôleur parle sur un canal VHF simulé, la parole est transcrite (Whisper adapté au domaine par LoRA), interprétée en ordres structurés par un grand modèle de langage contraint par une base de connaissances OACI, validée par des gardes déterministes (bornes physiques, graphe secteur), exécutée dans le simulateur de trafic BlueSky, puis collationnée par une voix de synthèse dégradée canal radio. Toutes les briques d'inférence respectent le contrat d'API OpenAI-compatible : le même système fonctionne indifféremment sur supercalculateur (ROMEO, GH200), sur GPU grand public local (RTX 4070) ou sur API cloud, par simple changement de configuration.

Nous validons chaque étage par des mesures contrôlées et reproductibles : (i) géométrie de conflit : 1 000 000 géométries Monte-Carlo sur 5 graines, 0 désaccord de décision avec une vérité numérique indépendante, et confrontation à BlueSky sur 200 rencontres ($F_1 = 1,0$); (ii) reconnaissance vocale : WER sur corpus VHF réels (ATCO2, UWB-ATCC), l'adaptation LoRA réduisant le WER ATCO2 de 71,9 % à 28,5 %; (iii) interprétation : comparaison appariée (McNemar) de quatre LLM locaux quantifiés et d'un parseur à règles sur 116 clairances annotées, dont des strates hors grammaire et adversariales; le meilleur modèle local (Mistral-7B) atteint 81,9 % d'exactitude TrafScript exacte, contre 100,0 % pour le parseur à règles sur la phraséologie standard mais 70,8 % hors grammaire; (iv) synthèse : coût temps réel et intelligibilité aller-retour; (v) boucle complète : 76 % de clairances parlées correctement exécutées (témoin texte : 88 %), latence vocale totale moyenne de 2,6 s. La campagne historique de validation se ré-exécute à l'identique (mêmes métriques champ à champ). L'ensemble du banc de mesure, des corpus annotés et des scripts d'analyse est versionné avec le projet.

1 Introduction

La formation initiale des contrôleurs aériens repose sur des simulateurs dont le coût d'exploitation est dominé par un facteur humain : chaque session requiert des *pseudo-pilotes*, opérateurs qui prononcent les collationnements et exécutent les instructions dans le simulateur. Automatiser ce rôle (comprendre une clairance parlée, l'exécuter fidèlement, la collationner d'une voix réaliste) est un cas d'usage exigeant pour les modèles de fondation : la phraséologie OACI est un langage contraint, le canal VHF (300–3 400 Hz) dégrade fortement le signal, et toute erreur d'interprétation exécutée dans le simulateur fausse l'exercice pédagogique.

Ce travail décrit un système complet et son évaluation : une application web d'entraînement (radar, strips, poste instructeur, exercices notés) adossée au simulateur de trafic open source BlueSky [1], dont la boucle radio est assurée par trois services d'inférence interchangeables au contrat OpenAI-compatible. Nos contributions :

1. une **architecture de sûreté en couches** : aucune sortie de LLM n'atteint le simulateur sans passer par une validation déterministe (bornes physiques, actions autorisées, waypoints du secteur), et toute panne de fournisseur est remontée visiblement (jamais de repli silencieux);
2. un **banc de mesure de bout en bout**, versionné et seedé, couvrant les cinq étages (géométrie/simulateur, STT, LLM, TTS, boucle vocale complète) avec intervalles de confiance bootstrap, IC de Wilson et tests appariés de McNemar;




FIGURE 1 – Architecture. Les briques IA (orange) sont des services OpenAI-compatibles interchangeables ; aucune sortie LLM n’atteint le simulateur sans la couche de validation déterministe (vert).

3. une **étude comparative multi-modèles reproductible sur GPU grand public** : quatre LLM open-weights quantifiés (1 à 7 milliards de paramètres) évalués *à travers le code de production*, comparés à un parseur à règles de référence, sur un corpus annoté stratifié (phraséologie standard, paraphrases hors grammaire, bruit STT, français, cas mixtes valide+invalide, négatifs de sécurité) ;
4. la **quantification de l’adaptation au domaine** : gain du LoRA ATC sur Whisper-small mesuré sur enregistrements VHF réels, effet du filtre passe-bande d’inférence, et coût (RTF) des points de déploiement local, cluster et cloud.

2 Système

2.1 Architecture

La figure 1 présente l’architecture. Le navigateur (React, canvas radar 60 fps, push-to-talk) communique avec un serveur FastAPI par REST et WebSocket (~ 8 Hz). Le simulateur BlueSky, non thread-safe, vit dans un thread unique alimenté par une file de commandes. Les trois briques d’inférence sont des services REST au contrat OpenAI standard (`/v1/audio/transcriptions`, `/v1/chat/completions`, `/v1/audio/speech`), configurés par variables d’environnement : changer de fournisseur, qu’il s’agisse de la façade auto-hébergée sur ROMEO, de la façade locale llama.cpp / faster-whisper / Kokoro (fournie avec le banc de mesure) ou d’une API cloud, ne modifie ni le code ni le comportement de validation.

2.2 Sûreté en couches

Le contrat d’interprétation impose un tableau JSON d’ordres `{callsign, action ∈ {HDG, ALT, SPD, ADDWPT}, value}`. En aval du modèle, une bibliothèque pure et testée (`03_bluesky_connector`) applique : coercition stricte de type (rejet des booléens, NaN, infinis), bornes physiques (HDG $[0; 360]^\circ$, ALT $[0; 45\,000]$ ft, SPD $[0; 350]$ kt), et validation des waypoints contre le graphe secteur. L’application ajoute deux gardes : un indicatif absent du radar produit un silence radio (réalisme assumé), et une incohérence sémantique montée/descente (« climb » vers un niveau inférieur au niveau courant) est rejetée avec message. Enfin, aucune panne de fournisseur n’est rattrapée silencieusement : erreur typée $\rightarrow$ HTTP 502 $\rightarrow$ événement visible dans le journal de bord de l’interface.

2.3 Adaptation au domaine

La brique STT est `openai/whisper-small` affiné par LoRA ($r = 32$, $\alpha = 64$, cibles q/v -proj) sur les corpus radiotéléphoniques réels UWB-ATCC et ATCOSIM [5, 6], avec un front-end reproduisant le canal : passe-bande Butterworth d’ordre 6, 300–3 400 Hz, et bruit additif (SNR 5–20 dB) à l’entraînement. Le prompt LLM inline une base de connaissances OACI originale de 9 fiches ($\sim 2,5$ Ko), couvrant les actions, les contextes informatifs à ignorer (QNH, transferts de fréquence) et la règle « en cas de doute, ne rien produire », ainsi que des indices NER (indicatif détecté). Le collationnement TTS applique la phraséologie OACI (chiffres parlés, alphabet radio, indicatifs en téléphonie) avec une voix stable par aéronef (hachage CRC32 de l’indicatif dans un pool configurable) et la dégradation VHF appliquée *côté client*, donc identique quel que soit le fournisseur.

3 Méthodologie

Principe. Chaque étage est mesuré à *travers le code de production* (mêmes prompts, mêmes clients HTTP, même post-traitement), jamais par une reconstitution. Tous les protocoles sont seedés et versionnés (**bench/**) ; chaque script écrit un JSON auto-porteur (protocole + résultats) et les figures et tableaux de cet article en sont générés automatiquement.

Statistiques. Moyennes : IC à 95 % par bootstrap percentile ($B = 10^4$, graine fixée). Proportions : IC de Wilson. Comparaisons de systèmes sur corpus apparié : test exact de McNemar (binomial) pour les issues binaires, bootstrap apparié pour les différences de WER. Percentiles de latence par interpolation linéaire.

Corpus d’interprétation. 116 clairances annotées en TrafScript attendu *après* validation : 68 cas historiques dans la grammaire du parseur de référence (10 catégories dont 10 négatifs) et 48 cas étendus couvrant paraphrases hors grammaire, bruit type STT (hésitations, répétitions), français parlé, nombres composés, immatriculations épelées, multi-ordres à connecteurs, cas *mixtes* (ordre valide + ordre invalide dans la même phrase, l’invalide devant être filtré et le valide conservé) et 14 négatifs de sécurité supplémentaires (hors bornes, hors schéma, instructions relatives, information pure). Un cas est réussi si le multi-ensemble TrafScript produit est exactement celui attendu.

Corpus audio. STT : 150 extraits par corpus, tirés au sort (graine 42, durées 0,4–30 s) de deux corpus VHF *réels*, ATCO2-1h (871 extraits disponibles, domaine cible jamais vu à l’entraînement du LoRA) et UWB-ATCC test (2 822 extraits, domaine d’entraînement) ; les IC bootstrap par extrait reflètent cette taille d’échantillon. Normalisation texte et WER identiques au protocole historique du projet (comparabilité avec les chiffres publiés). Boucle E2E : énoncés contrôleur synthétisés (voix Windows SAPI, jamais utilisée ailleurs dans le banc), passés dans le canal radio simulé (bruit SNR 12 dB puis passe-bande VHF).

Matériel. Étude locale : portable Windows 11, RTX 4070 Laptop 8 Go, i9-13900H, 32 Go. Mesures historiques ROMEO : nœud GH200 (Whisper-LoRA, Mistral-7B bf16, XTTS voix clonées) via tunnel SSH, reprises de `validation/results_perf.json`. LLM locaux : llama.cpp (CUDA), GGUF Q4_K_M, température 0, graine 42 : Llama-3.2-1B-Instruct, Qwen2.5-1.5B-Instruct, Qwen2.5-3B-Instruct et Mistral-7B-Instruct-v0.3, ce dernier étant le modèle servi sur ROMEO, ce qui permet une comparaison directe cluster/local.

4 Résultats

4.1 Géométrie de conflit et simulateur

Prédiction CPA vs vérité numérique. Sur 1 000 000 géométries aléatoires (5 graines $\times$ 200 000 ; positions ± 80 NM, caps uniformes, vitesses sol 150–550 kt), la décision du prédicteur de conflit embarqué (extrapolation linéaire, horizon 120 s, seuil 5 NM) coïncide avec une recherche numérique indépendante sur grille fine ($\Delta t = 0,05$ s, horizon 300 s) dans *tous* les cas : 0 désaccord sur 10^6 décisions. L’écart maximal sur la distance au point de rapprochement est de 0,05 NM, borné par la quantification d’affichage du champ (arrondi au dixième de NM) ; la campagne historique, qui comparait les valeurs non arrondies, mesurait un écart maximal de $5,52 \times 10^{-4}$ NM (figure 2).

Confrontation à BlueSky. La campagne historique (200 rencontres stabilisées, 55 % biaisées conflit, seuils 5 NM/120 s) donne précision, rappel et F_1 de 1,0 (113 conflits), MAE de 0,067 NM sur d_{CPA} et 0,71 s sur t_{CPA} . Nous l’avons ré-exécutée intégralement : toutes les métriques sont identiques champ à champ à celles versionnées (seules les durées d’exécution diffèrent), ce qui établit la reproductibilité du protocole.

Garantie de conflit des exercices. Le générateur d’exercices construit des paires d’aéronefs convergeant vers un point commun avec temps d’arrivée égaux. Sur 2 000 tirages, la garantie est vérifiée à 100,0 % : d_{CPA} analytique maximal de 0,082 NM (moyenne 0,018 NM, très inférieure à la norme de séparation de 5 NM) et écart maximal entre l’instant de croisement annoncé et le CPA calculé de 0,7 s (figure 3).

Montée en charge. BlueSky headless avance 10 s de simulation avec un facteur temps réel moyen de $\times 105$ à 5 aéronefs et encore $\times 67$ à 200 aéronefs (5 répétitions par point, figure 4) : la simulation n’est jamais le facteur limitant de la boucle vocale.




FIGURE 2 – Erreur de d_{CPA} du prédicteur embarqué vs grille numérique fine, par graine (200 000 géométries chacune). L’erreur est bornée par l’arrondi d’affichage (0,05 NM) ; la décision de prédiction est exacte (0 désaccord / 10^6).




FIGURE 3 – Garantie « conflit par construction » du générateur d’exercices : distribution du d_{CPA} analytique sur 2 000 tirages seedés.

4.2 Reconnaissance vocale (STT)

Le tableau 1 et la figure 5 comparent cinq systèmes sur les deux corpus VHF réels, avec et sans passe-bande VHF d’inférence (protocole de production : *avec*). Trois enseignements :

1. **L’adaptation LoRA est le facteur dominant.** Sur ATCO2 (domaine jamais vu à l’entraînement), le LoRA réduit le WER de 71,9 % (vanilla) à 28,5 %, gain relatif d’environ 60 % confirmé par bootstrap apparié (différence significative, l’IC de la différence excluant zéro). Sur UWB-ATCC (domaine d’entraînement), le WER tombe à 19,2 %.
2. **Le passe-bande d’inférence est cohérent avec l’entraînement.** Il améliore ou laisse inchangé le modèle adapté (entraîné dans ce domaine), tandis que son effet sur les modèles génériques est faible : le choix de production (`bandpass=True`) est validé.
3. **Le déploiement local est réaliste.** En greedy sur RTX 4070, tous les systèmes tournent bien en deçà du temps réel (figure 6) ; faster-whisper offre le meilleur débit brut, la voie transformers+LoRA offrant elle la meilleure exactitude.

4.3 Interprétation des clairances (LLM)

Le tableau 2 et les figures 7–9 présentent l’étude comparative sur les 116 clairances. Lecture :

1. **Le parseur à règles est parfait dans sa grammaire, nul en dehors.** 100,0 % sur la phraséologie standard, 70,8 % sur les strates hors grammaire : c’est précisément l’écart que le LLM doit combler.
2. **L’échelle compte, mais pas de façon monotone.** L’exactitude globale croît de 3,4 % (Llama-3.2-1b) à 81,9 % (Mistral-7B) ; les différences entre modèles sont testées par McNemar apparié (tableau 3).




FIGURE 4 – Montée en charge BlueSky headless (5 répétitions par point, IC bootstrap à 95 %).

TABLE 1 – STT : WER corpus (%) et RTF par système, corpus VHF réels, sans/avec passe-bande VHF d’inférence. Normalisation du protocole historique du projet ; décodage greedy.

	atco2 (n=150)			uwb_atcc (n=150)		
	brut	VHF	RTF	brut	VHF	RTF
hf-small	71,1	71,9	0,018	101,2	91,9	0,023
hf-small-lora	29,7	28,5	0,017	19,3	19,2	0,020
fw-tiny	100,9	106,0	0,106	120,1	123,3	0,112
fw-base	88,1	90,1	0,091	107,4	110,8	0,148
fw-small	70,6	71,5	0,092	93,2	92,3	0,130

Une anomalie notable : Qwen2.5-3B s’effondre ($\approx 24\%$) là où son cadet 1.5B excelle : il honore le message système (vérifié) mais viole le schéma (champ `callsign` omis, clés JSON non citées). Nous avons exclu un artefact de conversion en ré-évaluant un second GGUF indépendant (bartowski) : résultat identique (23,3 %). Autre artefact *réellement* rencontré puis corrigé : le gabarit de conversation Mistral-v0.3 de llama.cpp *perd le message système* (vérifié par test dédié), faisant chuter Mistral-7B à 21 % ; la fusion système→utilisateur du gabarit officiel restaure 81,9 %. Ces deux cas illustrent pourquoi l’évaluation doit se faire *à travers la pile de déploiement réelle*.

3. **La sécurité tient d’abord aux gardes déterministes.** Les taux de rejet des négatifs par système (tableau 2) montrent que même les petits modèles, qui hallucinent des ordres, sont largement rattrapés par la validation de bornes et de waypoints, illustration chiffrée de l’architecture en couches (§2.2).
4. **Latence exploitable en local.** Le meilleur compromis qualité/latence locale est Mistral-7B (81,9 %, 0,8 s par clairance en moyenne) ; Mistral-7B, identique au modèle ROMEO, sert de point de comparaison cluster/local.

Génération de situations. Sur les 20 descriptions instructeur de la validation historique (116 contraintes vérifiables : effectifs, niveaux, caps, azimuts, espacements, types), le générateur à règles atteint 100,0 % et le meilleur LLM local 71,8 % (figure 10) : la tâche, plus ouverte (géométrie du secteur, espacement en traînée), reste sensiblement plus difficile que l’extraction d’ordres pour les petits modèles.

4.4 Synthèse vocale (TTS)

Le tableau 4 et la figure 11 évaluent Kokoro-82M (4 voix) et Windows SAPI sur les collationnements produits par le générateur de phraséologie du projet. Kokoro synthétise à RTF 0,336 et son intelligibilité aller-retour (WER d’un juge STT fixe) reste à 21,4 % *après* dégradation VHF : la coloration radio coûte peu d’intelligibilité, conformément à l’objectif (réalisme sans perte pédagogique). La métrique étant relative (biais du juge partagé), seuls les écarts entre moteurs sont interprétables.




FIGURE 5 – WER par système sur corpus VHF réels (IC bootstrap 95 % du WER moyen par extrait ; losanges : WER corpus). Protocole de normalisation identique aux mesures historiques du projet.




FIGURE 6 – Facteur temps réel STT (log) : tous les systèmes sont largement sous le temps réel sur GPU grand public.

4.5 Boucle vocale complète (E2E)

La figure 12 et le tableau 5 mesurent la boucle complète de production sur 25 clairances parlées (canal radio SNR 12 dB) : 76 % d'exécutions exactes en condition voix, contre 88 % en condition témoin texte (mêmes clairances, sans STT) ; l'écart chiffre le coût résiduel de l'étage STT, et l'attribution des échecs (transcription déviée vs interprétation) est donnée dans le tableau 5. La latence vocale totale (STT + LLM + TTS, dégradation VHF cliente comprise) est de 2,6 s en moyenne (p95 3,2 s), compatible avec le rythme d'un exercice d'entraînement, l'étage LLM dominant le budget.

4.6 Référence cluster (ROMEO) et continuité de service

Les mesures historiques sur GH200 (Whisper-LoRA, Mistral-7B bf16, XTTS) restent la référence de qualité maximale : interprétation moyenne 5,2 s (min 0,98), ASR 0,84 s (RTF 0,04), TTS 3,9 s (RTF 0,82), WER de re-transcription de la boucle vocale ~22 %. La présente étude montre qu'un poste local à GPU grand public reproduit la même architecture avec des latences du même ordre et des modèles plus petits, au prix mesuré ici ; l'écart de qualité entre Mistral-7B bf16 (cluster) et Q4_K_M (local) étant lui-même borné par les résultats du tableau 2.

Fait opérationnel notable : pendant la campagne locale (juillet 2026), le supercalculateur ROMEO était *entièrement indisponible* (maintenance de sécurité, correctifs RedHat en attente sur les nœuds de connexion et de calcul). L'application est restée pleinement fonctionnelle par simple bascule de la configuration `.env` vers la façade locale, validation en conditions réelles de l'argument de continuité de service du contrat OpenAI-compatible.

TABLE 2 – Interprétation : exactitude TrafScript exacte (IC Wilson 95 %), par strate, rejet des négatifs de sécurité, JSON strict, latence et débit (116 clairances ; chaîne de production complète).

Système	Globale	IC 95 %	Std.	Hors gr.	Nég. rejetés	JSON	Lat. moy.
Parseur à règles	87,9	[81 ; 93]	100	71	96	100	0,00 s
Llama-3.2-1b	3,4	[1 ; 9]	1	6	17	22	2,81 s
Mistral-7B	81,9	[74 ; 88]	85	77	75	100	0,82 s
Qwen2.5-3b-bartowski	23,3	[17 ; 32]	21	27	96	69	0,42 s
Qwen2.5-1.5b	75,0	[66 ; 82]	79	69	75	97	0,32 s
Qwen2.5-3b	24,1	[17 ; 33]	19	31	100	46	0,34 s

TABLE 3 – Tests exacts de McNemar entre systèmes appariés sur les 116 clairances (n_{01} : A correct / B faux).

Paire (A vs B)	n_{01}	n_{10}	p
Parseur à règles vs Llama-3.2-1b	98	0	$< 10^{-4}$
Parseur à règles vs Mistral-7B	19	12	0,2810
Parseur à règles vs Qwen2.5-3b-bartowski	76	1	$< 10^{-4}$
Parseur à règles vs Qwen2.5-1.5b	25	10	0,0167
Parseur à règles vs Qwen2.5-3b	75	1	$< 10^{-4}$
Llama-3.2-1b vs Mistral-7B	0	91	$< 10^{-4}$
Llama-3.2-1b vs Qwen2.5-3b-bartowski	0	23	$< 10^{-4}$
Llama-3.2-1b vs Qwen2.5-1.5b	1	84	$< 10^{-4}$
Llama-3.2-1b vs Qwen2.5-3b	0	24	$< 10^{-4}$
Mistral-7B vs Qwen2.5-3b-bartowski	73	5	$< 10^{-4}$
Mistral-7B vs Qwen2.5-1.5b	16	8	0,1516
Mistral-7B vs Qwen2.5-3b	73	6	$< 10^{-4}$
Qwen2.5-3b-bartowski vs Qwen2.5-1.5b	7	67	$< 10^{-4}$
Qwen2.5-3b-bartowski vs Qwen2.5-3b	3	4	1,0000
Qwen2.5-1.5b vs Qwen2.5-3b	65	6	$< 10^{-4}$

5 Menaces à la validité

Interne. Les énoncés E2E sont synthétiques (voix SAPI + canal simulé) : le WER STT y est optimiste par rapport à de la parole spontanée ; les corpus ATCO2/UWB (voix réelles) couvrent ce risque pour l’étage STT isolé. L’intelligibilité TTS partage le biais du juge STT entre moteurs (métrique relative). L’erreur CPA mesurée est bornée par l’arrondi d’affichage du champ comparé. **Externe.** Les LLM locaux sont quantifiés Q4_K_M : les mêmes modèles en pleine précision (cas ROMEO) peuvent faire légèrement mieux ; inversement les fournisseurs cloud ne sont pas évalués ici (le contrat les rend interchangeables, pas équivalents). Le corpus d’interprétation, quoique stratifié et adversarial, reste de taille modeste (116) ; les IC de Wilson en tiennent compte. **Construction.** La vérité terrain des cas mixtes suppose la politique « filtrer l’invalidé, garder le valide », qui est celle du système ; un système plus conservateur (tout rejeter en cas de doute) serait pénalisé par cette métrique ; le taux de rejet des négatifs est donné séparément pour cette raison.

6 Travaux liés

Les corpus ATCOSIM, UWB-ATCC et le challenge ATCO2 [6, 5, 4] ont établi la reconnaissance vocale ATC comme domaine propre, avec des WER de systèmes génériques dégradés de plusieurs dizaines de points par le canal VHF ; l’adaptation de Whisper [2] par LoRA [3] est aujourd’hui l’approche dominante. BlueSky [1] est le simulateur ouvert de référence pour la recherche ATM. L’utilisation de LLM contraints pour l’interprétation de clairances rejoint les travaux sur l’extraction structurée fiable ; notre apport est l’évaluation *système* (à travers la chaîne de production complète, gardes comprises) plutôt que l’évaluation isolée du modèle, et la comparaison appariée à un parseur à règles sur un corpus stratifié.

7 Conclusion

Nous avons présenté un simulateur d’entraînement ATC dont chaque étage (géométrie de conflit, reconnaissance vocale, interprétation, synthèse, boucle complète) est validé par des mesures contrôlées, seedées et versionnées avec le code. Les résultats établissent : une base géométrique exacte (10^6 décisions sans désaccord,




FIGURE 7 – Exactitude TrafScript exacte par système (IC Wilson 95 %), globale et par strate. La chaîne évaluée est celle de production (prompt + KB OACI + validation déterministe).

TABLE 4 – TTS : RTF et intelligibilité aller-retour (juge faster-whisper small (cuda, greedy)) sur 30 collationnements OACI.

Moteur / voix	RTF	WER propre	WER après VHF
kokoro/af_bella	0,348	22,5 %	25,4 %
kokoro/am_adam	0,346	18,2 %	17,7 %
kokoro/bf_emma	0,339	21,2 %	19,8 %
kokoro/bm_george	0,310	26,0 %	22,6 %
sapi/Microsoft Zira Desktop	0,003	16,0 %	18,2 %

$F_1 = 1,0$ face à BlueSky, conflits d'exercice garantis à 100,0 %) ; un gain STT majeur et significatif de l'adaptation au domaine ; une hiérarchie nette des LLM locaux avec un point de fonctionnement exploitable sur GPU grand public ; et une boucle vocale complète à 76 % de réussite pour 2,6s de latence moyenne. L'architecture au contrat OpenAI-compatible rend ces points de déploiement (cluster, local, cloud) interchangeables sans toucher au code ni aux gardes de sûreté, qui restent déterministes et testées.

Reproductibilité. Code, corpus annotés, scripts de benchmark, résultats JSON et génération des figures et tableaux de cet article : répertoires `bench/`, `validation/` et `docs/article/` du dépôt. La campagne historique ré-exécutée produit des métriques identiques champ à champ.

Références

- [1] J. M. Hoekstra et J. Ellerbroek, « BlueSky ATC Simulator Project : an Open Data and Open Source Approach », *ICRAT*, 2016.
- [2] A. Radford *et al.*, « Robust Speech Recognition via Large-Scale Weak Supervision », *ICML*, 2023.
- [3] E. Hu *et al.*, « LoRA : Low-Rank Adaptation of Large Language Models », *ICLR*, 2022.
- [4] J. Zuluaga-Gomez *et al.*, « ATCO2 corpus : A Large-Scale Dataset for Research on Automatic Speech Recognition and Natural Language Understanding of Air Traffic Control Communications », 2022.
- [5] L. Šmídl *et al.*, « Air Traffic Control Communication (UWB-ATCC) Corpus », Université de Bohême de l'Ouest, 2019.
- [6] K. Hofbauer, S. Petrik et H. Hering, « The ATCOSIM Corpus of Non-Prompted Clean Air Traffic Control Speech », *LREC*, 2008.
- [7] A. Q. Jiang *et al.*, « Mistral 7B », 2023.
- [8] Équipe Qwen, « Qwen2.5 Technical Report », 2024.




FIGURE 8 – Exactitude par catégorie de clairance et par système.

- [9] OACI, *Doc 4444 : Gestion du trafic aérien (PANS-ATM)*, 16^e éd. (phraséologie de référence ; la base de connaissances du projet est un contenu original, sans extrait verbatim).




FIGURE 9 – Latence d’interprétation et débit de génération des modèles locaux (RTX 4070, llama.cpp Q4_K_M, température 0).




FIGURE 10 – Conformité aux contraintes du générateur de situations (IC Wilson 95 %).




FIGURE 11 – TTS : coût de synthèse et intelligibilité objective aller-retour, avant/après canal VHF.

TABLE 5 – Boucle vocale complète : configuration, réussite, attribution des échecs et latences par étage.

Clairances parlées (canal SNR 12 dB)	25
Réussite voix (IC Wilson)	76 % [57 ; 89]
Réussite témoin texte	88 %
Échecs attribués STT / LLM / fournisseur	3 / 3 / 0
Latence STT (moy. / p95)	0,36 / 0,42 s
Latence LLM (moy. / p95)	1,06 / 1,42 s
Latence TTS (moy. / p95)	1,15 / 1,36 s
Latence totale (moy. / p95)	2,57 / 3,20 s




FIGURE 12 – Boucle vocale complète : taux de réussite (voix vs témoin texte, IC Wilson) et décomposition de la latence.